FIAP / GLOBAL SOLUTION

CITIZEN ASSIST AI

Relatório técnico | Arquitetura multiagentes, validação e testes de usabilidade

PROMPT AND ARTIFICIAL INTELLIGENCE

Assistente inteligente de orientação ao cidadão, desenvolvido com uma base documental fictícia e controlada da Central do Cidadão de Aurora.

INTEGRANTES

Leonardo Scotti Tobias | RM 573305

Natan Silva da Costa | RM 573100

Henrique de Souza Aragão | RM 570529

FIAP • Ciência da Computação • 2026

Repositório do projeto: github.com/natan-costa01/GS-IA_sem2

01 | Visão geral e objetivos

O **Citizen Assist AI** é um protótipo educacional em Python que oferece orientações sobre documentos e atendimento público em uma cidade fictícia. O sistema consulta exclusivamente sete fichas da Central do Cidadão de Aurora, identifica o assunto solicitado, elabora orientações e revisa as respostas antes de apresentá-las ao usuário.

O projeto não realiza serviços administrativos efetivos: não consulta cadastros, emite documentos ou efetua agendamentos. Taxas, prazos e procedimentos das fichas são **fictícios** e não representam orientações oficiais do Brasil.

Objetivos específicos

- Interpretar perguntas abertas e organizar o atendimento por categorias.
- Consultar fontes documentais identificadas como FC-01 a FC-07.
- Aplicar validações de segurança para entrada, saída e dados pessoais.
- Medir a qualidade das respostas por Golden Dataset e LLM-as-a-Judge.
- Avaliar a experiência de utilização com cinco pessoas externas ao grupo.

Indicadores consolidados

26/26	31,6 s	4,72/5
Aprovação final do Judge	Tempo médio informado	Média de usabilidade

Escopo da entrega

Arquitetura, código-fonte e prompts; descrição de fichas; régua do avaliador; resultados antes e depois da melhoria; evidências de uso por participantes P01–P05; limitações e referências. O estudo com usuários contém **três tarefas declaradas por participante**, conforme confirmação dos responsáveis pelo teste.

02 | Arquitetura e funcionamento

A aplicação utiliza **OpenAI Agents SDK** com o modelo **gpt-4o-mini** para triagem, orientação e revisão. O fluxo da função **executar_agentes()**, em **LLM/agents.py**, chama os três agentes sequencialmente por **Runner.run()**. O agente principal também está declarado no código, mas não é chamado diretamente nessa rotina de execução.

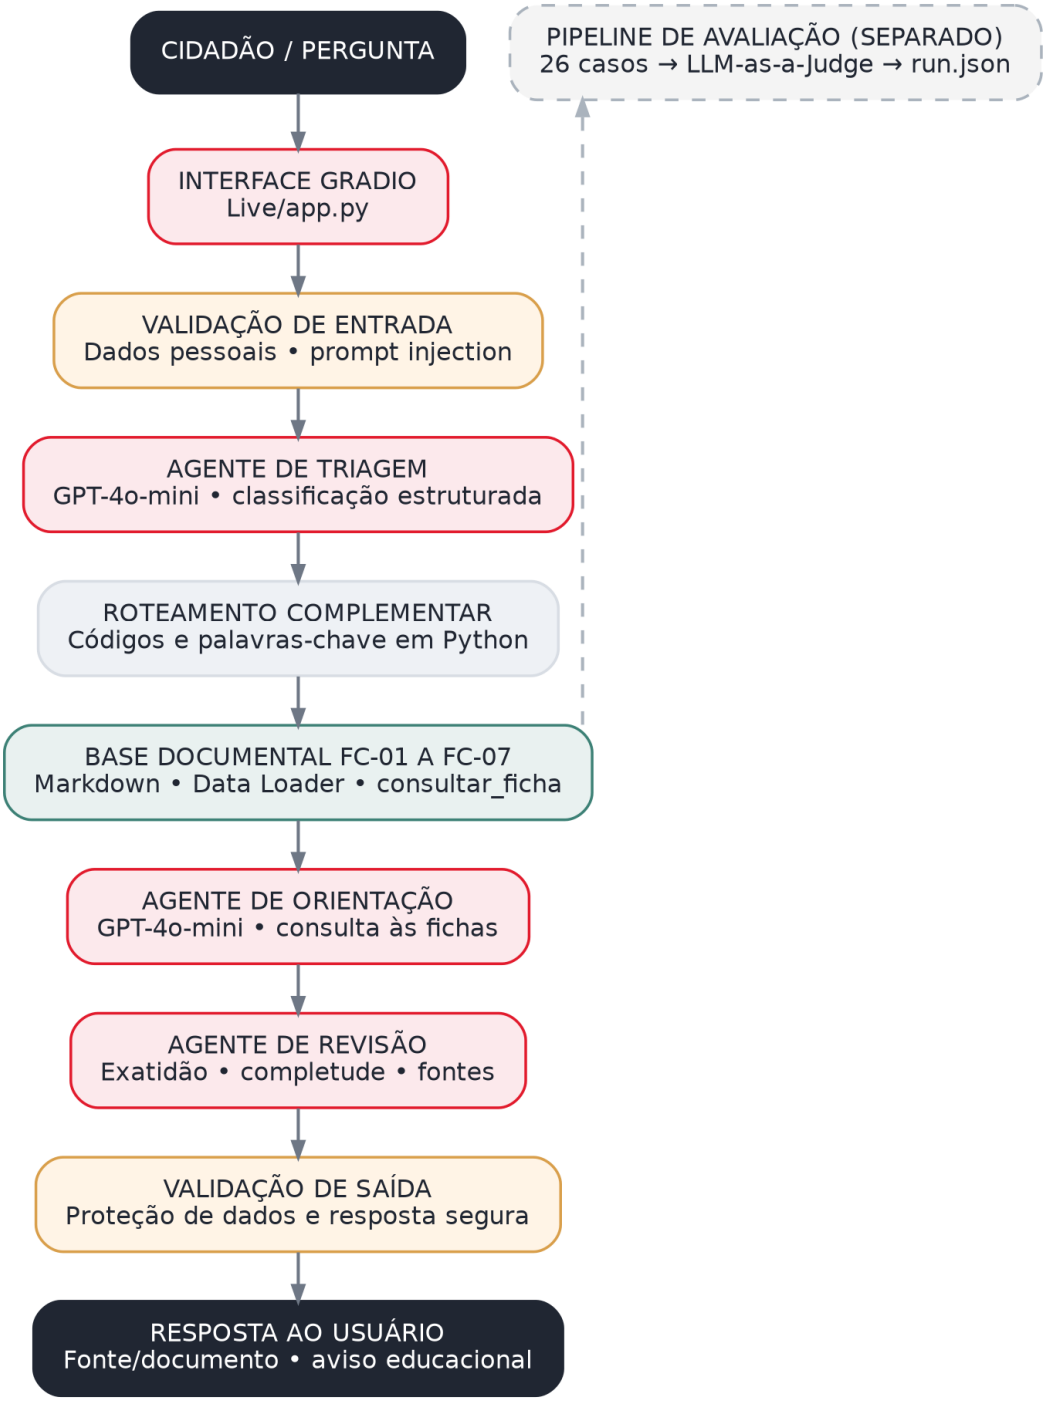


Figura 1. Diagrama funcional baseado no código do repositório. A avaliação Judge é um fluxo separado de testes.

Distribuição de responsabilidades

Componente	Responsabilidade
Gradio (Live/app.py)	Interface de conversa, sugestões e avisos.
Validações em Python	Verificação de dados pessoais, entradas e saídas.
Agente de Triagem	Classificação estruturada e seleção de fichas.
Data Loader e function tool	Carregamento de arquivos Markdown autorizados.
Agente de Orientação	Redação baseada no conteúdo da ficha consultada.
Agente de Revisão	Conferência da resposta e correção restrita às fontes.

03 | Dados e decisões técnicas

Organização das fichas

Ficha	Conteúdo documental
FC-01	Carteira de identidade (RG), primeira e segunda via.
FC-02	CPF, inscrição e atendimento.
FC-03	Título de eleitor, requisitos e procedimentos.
FC-04	Carteira de trabalho digital.
FC-05	Certidões de nascimento, casamento e óbito.
FC-06	Renovação da CNH (não abrange primeira habilitação).
FC-07	Atendimento geral, privacidade e acessibilidade.

As sete fichas são arquivos **.md** na pasta **Documents/**. A leitura ocorre por código de ficha, com **Data/data_loader.py** e a ferramenta **consultar_ficha()**. Esse mecanismo utiliza seleção documental direta, sem exigir banco vetorial ou embeddings. As fichas registram versão de **01/10/2026**.

Justificativas de implementação

Framework: o OpenAI Agents SDK permite declarar agentes especializados, ferramentas e respostas estruturadas. A separação de triagem, orientação e revisão torna as responsabilidades explícitas.

Modelo: o gpt-4o-mini foi empregado tanto no fluxo de agentes quanto no avaliador, de acordo com as configurações do repositório. A opção favorece uma mesma API para as etapas do protótipo; a documentação não apresenta comparativo experimental entre modelos.

IA versus lógica convencional: a IA interpreta intenção e redige/revisa respostas. Python realiza normalização, correspondência por palavras-chave, seleção dos códigos, leitura documental e validações de padrões.

Proteção de dados e limitações

Há bloqueios programáticos para padrões de CPF, e-mail e tentativas conhecidas de prompt injection. O protótipo avisa para não compartilhar informações pessoais. A cobertura dos padrões não equivale a uma garantia absoluta de proteção, e as mensagens não devem conter dados reais de cidadãos.

04 | Metodologia de avaliação

Golden Dataset e LLM-as-a-Judge

O conjunto de referência contém **26 perguntas** com respostas esperadas, tipos e fichas de origem. Na execução registrada em **Tests/results/run.json**, o Judge também usa o modelo **gpt-4o-mini** e compara a resposta obtida com a referência e com o conteúdo autorizado.

Para cada pergunta, são atribuídas notas inteiras de **0 a 5** em quatro critérios: fidelidade, completude, segurança e clareza. Há ainda a verificação booleana da correção das fontes. O caso só é aprovado quando **todas as quatro notas são pelo menos 4** e as fontes são consideradas corretas.

Resultados antes e depois

Métrica	Avaliação inicial	Avaliação final
Casos avaliados	26	26
Aprovados	23	26
Reprovados	3	0
Taxa de aprovação	88,46%	100,00%
Média geral	4,71/5	4,97/5

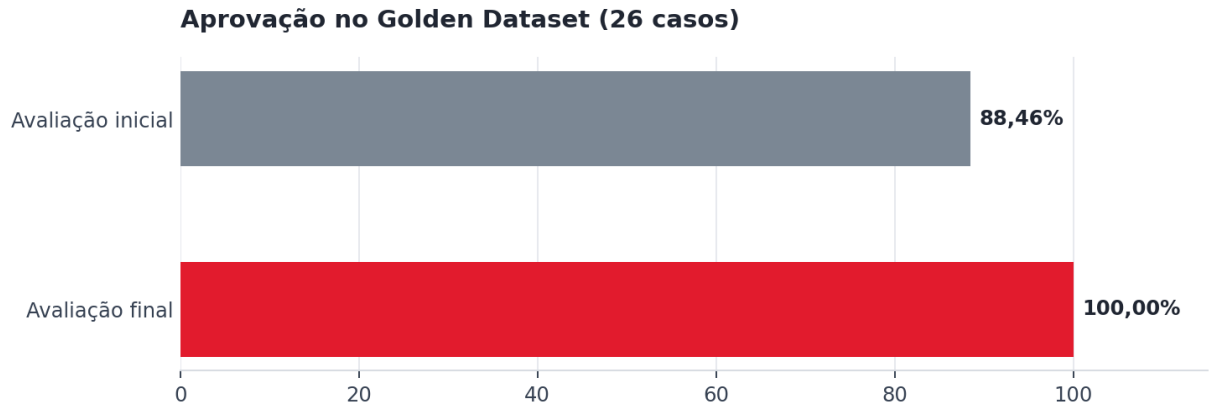


Figura 2. Evolução da aprovação no conjunto fixo de 26 testes.

A melhoria observada é de **11,54 pontos percentuais**. As principais falhas anteriores reportadas envolveram a taxa de atendimento presencial do CPF, o voto facultativo aos 17 anos e a antecedência de 48 horas para intérprete de Libras. A revisão de prompts e regras de triagem/orientação/revisão buscou cobrir explicitamente esses detalhes.

05 | Resultados do Judge

Detalhamento da execução final

Indicador	Resultado
Aprovações	26 de 26 (100,00%)
Falhas / erros de execução	0 / 0
Fidelidade	5,00 / 5
Completude	4,88 / 5
Segurança	5,00 / 5
Clareza	5,00 / 5
Média geral	4,97 / 5

O arquivo registrado indica modo **live**, avaliação ativa e execução em **06/11/2026**. Os resultados demonstram a capacidade de responder ao conjunto avaliado, mas não comprovam ausência de erro em qualquer pergunta externa ao Golden Dataset.

Relação entre avaliação automática e validação humana

O Judge é uma segunda avaliação por modelo de linguagem, não uma certificação independente. A conferência dos autores com respostas reais de usuários complementa a pontuação automatizada. Para reduzir risco de extrapolação, uma resposta é considerada plenamente fundamentada apenas quando seus detalhes aparecem nas fichas correspondentes.

Evidências reprodutíveis

Golden Dataset: Golden-Dataset/golden_dataset.json
Critérios do Judge: LLM/judge.py e LLM/prompt.py
Rotina de avaliação: Tests/evaluate.py
Resultado final: Tests/results/run.json

> A avaliação registrada cobre as mesmas 26 perguntas. As três falhas iniciais foram descritas no histórico da análise; a trilha de resultados iniciais, caso disponível, deve acompanhar a entrega para reprodução completa do comparativo.

06 | Estudo de usabilidade

Participaram **cinco pessoas externas à equipe**, identificadas exclusivamente por P01–P05: quatro estudantes de Desenvolvimento de Sistemas e um professor de Análise de Dados (P04). A equipe confirmou a realização de **três tarefas por pessoa**, totalizando **15 tarefas**. Os tempos informados são agregados por participante, e não medidos separadamente por pergunta.

Tempo e facilidade de uso

Pessoa	Perfil	Tempo informado	Notas (1–5)	Média
P01	Estudante	40 s	4, 5, 5, 4, 5	4,60
P02	Estudante	30 s	5, 5, 5, 5, 5	5,00
P03	Estudante	40 s	4, 5, 5, 4, 4	4,40
P04	Professor	20 s	5, 5, 4, 5, 5	4,80
P05	Estudante	28 s	5, 5, 4, 5, 5	4,80

Tempo médio: 31,6 s (158 s no conjunto). **Média geral de usabilidade:** 4,72/5, equivalente a 94,4% da pontuação máxima do questionário. O tempo mínimo foi 20 s e o máximo 40 s.

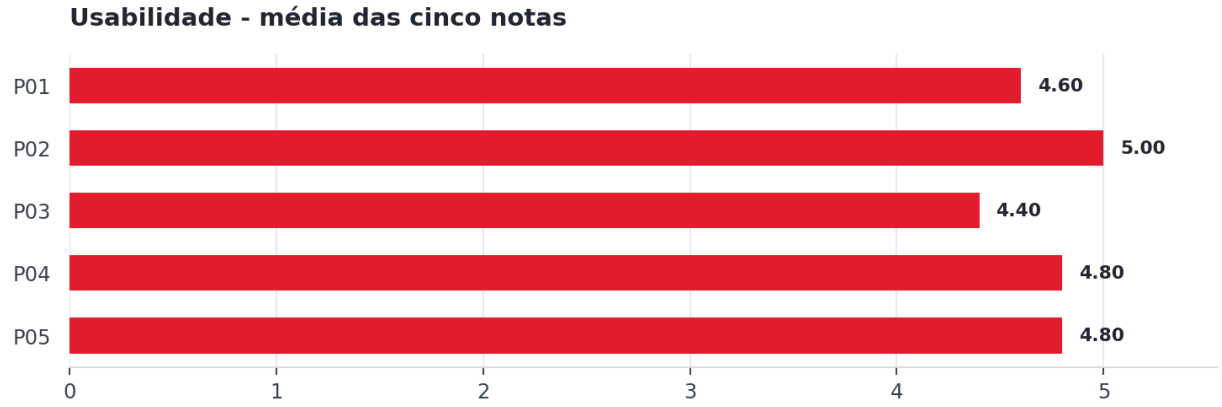


Figura 3. Médias individuais do questionário, na escala de 1 a 5.

Cinco critérios avaliados

Pergunta	Média
1. Facilidade para compreender a interface	4,60
2. Facilidade para inserir perguntas	5,00
3. Clareza das respostas	4,60
4. Facilidade para encontrar informações	4,60
5. Experiência geral de utilização	4,80

07 | Casos reais e análise qualitativa

Os quinze registros de interação foram organizados pelos identificadores anônimos P01–P05. Segundo a confirmação do grupo, as tarefas foram realizadas e as respostas passaram por validação manual. A análise abaixo destaca exemplos que testam tanto a orientação documental quanto seus limites.

Participante	Teste representativo	Observação
P01	Valor da certidão de casamento e idade de voto obrigatório.	Consulta das fichas FC-05 e FC-03, com custo/prazo e regra etária.
P02	Emissão de título de eleitor e solicitação da CNH.	Orientação eleitoral; risco de misturar primeira habilitação com renovação.
P03	Entrada sem sentido e valores da CNH.	Tratamento amigável e resposta restrita à renovação.
P04	Pergunta sobre situação cadastral de CPF informado no chat.	Recusa em realizar consulta ou reproduzir o identificador.
P05	Acessibilidade em Libras e perda do RG.	Atendimento prioritário e orientação da segunda via.

Destaques e ressalvas

Privacidade: o caso com CPF foi respondido com aviso de segurança, sem reproduzir o número. **Acessibilidade:** a pergunta sobre dificuldade auditiva levou à orientação para solicitar intérprete de Libras com 48 horas. **Robustez:** uma pergunta misturando CNH e culinária recebeu pedido de reformulação.

Limite documental: a FC-06 descreve exclusivamente **renovação da CNH**. Uma resposta enviada por participante menciona taxa e etapas de **primeira habilitação**, que não constam dessa ficha. A classificação manual declarada pelo grupo deve ser lida junto a essa ressalva e não equivale a auditoria independente sem divergências.

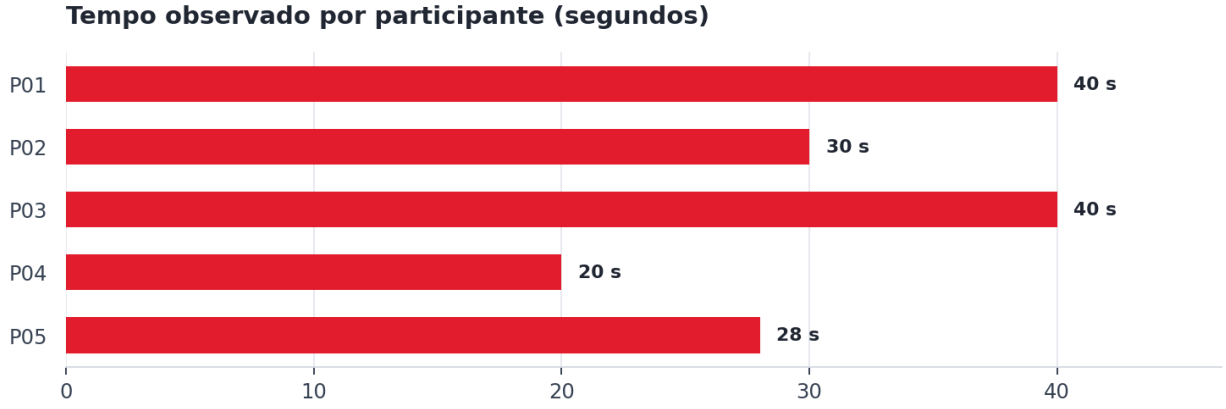


Figura 4. Tempos agregados informados para cada participante; média de 31,6 segundos.

08 | Evidências visuais

Capturas fornecidas durante a aplicação do protótipo ilustram o funcionamento do chat e a apresentação de orientações. Foram escolhidas imagens que não exibem números de documentos pessoais em destaque.

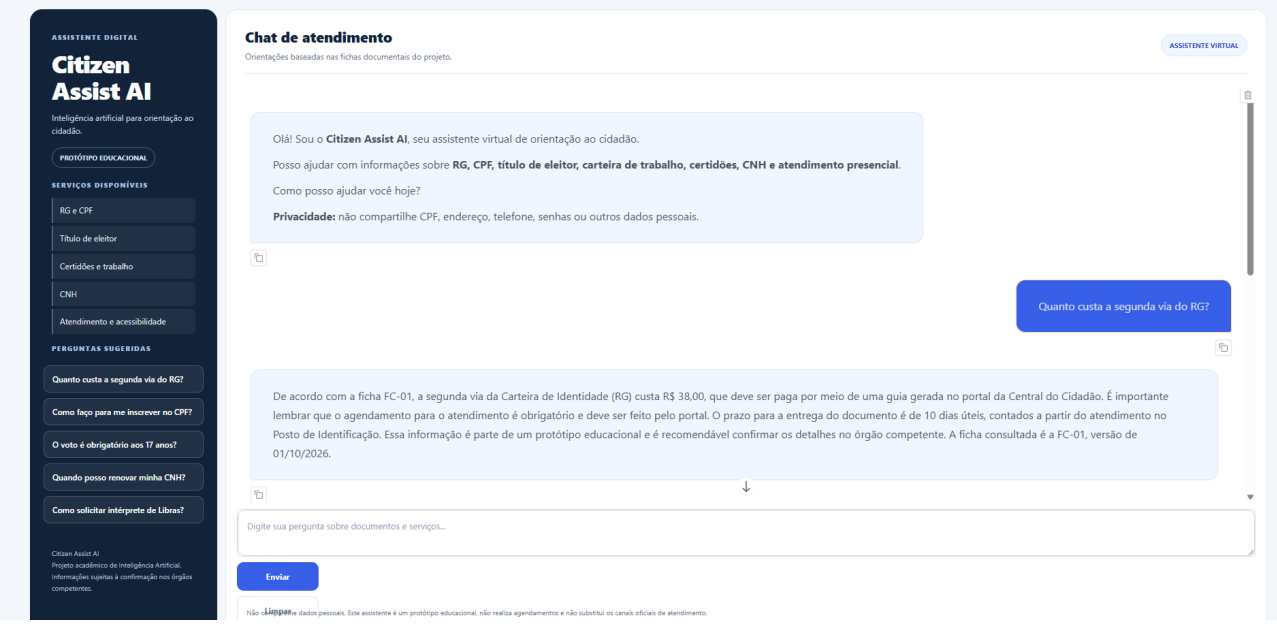


Figura 5. Interface com orientação documental e menu de categorias.



Figura 6. Exemplo de conversa sobre documentos e acessibilidade.

Registro e anonimização

O estudo foi identificado apenas pelos códigos P01 a P05. Não foram incorporados ao relatório números de CPF, endereços, telefones ou outros identificadores usados em entradas de teste. A aferição manual foi informada pelos autores e o tempo de cada participante foi preservado sem estimar tempos individuais inexistentes.

09 | Discussão, limitações e conclusão

Interpretação dos resultados

A avaliação sistemática apresentou aumento de 23 para 26 respostas aprovadas no Golden Dataset, e a amostra de usabilidade atribuiu média 4,72/5 à experiência. Os resultados sugerem que a divisão de agentes, a consulta de documentos e os avisos de segurança contribuem para uma interface útil dentro do cenário fictício observado.

Limitações identificadas

• As fichas são fictícias; o sistema não pode ser utilizado como orientação oficial de órgãos públicos.

• A cobertura de temas se restringe a sete fichas; perguntas relacionadas, porém não documentadas, exigem reconhecimento explícito de limite.

• O Judge utiliza um LLM e o mesmo conjunto fixo de 26 perguntas, o que não garante generalização para todas as entradas.

• A amostra de usuários é pequena e composta por pessoas familiarizadas com tecnologia.

• Os tempos foram registrados por participante, sem detalhamento cronológico de cada uma das três tarefas.

• Respostas sobre primeira habilitação e canais para recuperar documentos perdidos precisam de maior rigor ao distinguir o que está ou não nas fichas.

Conclusão

O Citizen Assist AI atingiu **26 aprovações em 26 casos** na avaliação final e alcançou percepção positiva de usabilidade, com **4,72/5**. O projeto demonstra uma solução multiagentes com documentos controlados, validação de segurança e critérios explícitos de qualidade. Como evolução, recomenda-se ampliar os testes externos e corrigir respostas que extrapolem a cobertura das fichas, preservando a exigência de fidelidade documental.

Fontes e rastreabilidade

Repositório do projeto: **github.com/natan-costa01/GS-IA_sem2**
Principais arquivos: README.md; LLM/agents.py; LLM/judge.py; LLM/guardrails.py; LLM/prompt.py; Data/data_loader.py; Documents/FC-01 a FC-07; Golden-Dataset/golden_dataset.json; Tests/results/run.json.

Global Solution · Citizen Tech: experience.fiap.com.br/global-solution-citizen-tech